Pack Livrables – Modélisation, Architecture et Documentation

SmartShop 360

23 février 2026

Table des matières

1 Vue Métier

Livrable Urbaniste – Vue Métier

SmartShop 360

23 février 2026

Objectif

Cette vue représente les **acteurs** et les **processus métier** existants :
— Vente sur site
— Vente marketplace
— Analyse qualité

Acteurs

— Client Web
— Client Marketplace
— Analyste Data
— Responsable Qualité / Marketing
— Service Commercial
— Agent IA SmartShop 360

Processus

1. Le client passe commande via site ou marketplace.
2. Les ventes alimentent la source ERP et les avis alimentent la source JSON.
3. Le pipeline ETL unifie les référentiels produits (MDM) pour croiser ventes et avis.
4. Le responsable qualité/marketing exploite les alertes et KPI croisés.
5. Le service commercial et l'agent IA exploitent les résultats pour la décision.

Alignement avec le code

— Interface métier : `app.py` et modules `src/ui/*`
— Questions métiers en langage naturel : `src/ui/chat.py`
— Agent Text-to-SQL : `src/agent/graph.py`
— Alertes métiers (CRITIQUE / A_SURVEILLER) : vue `v_alerts`

Diagramme

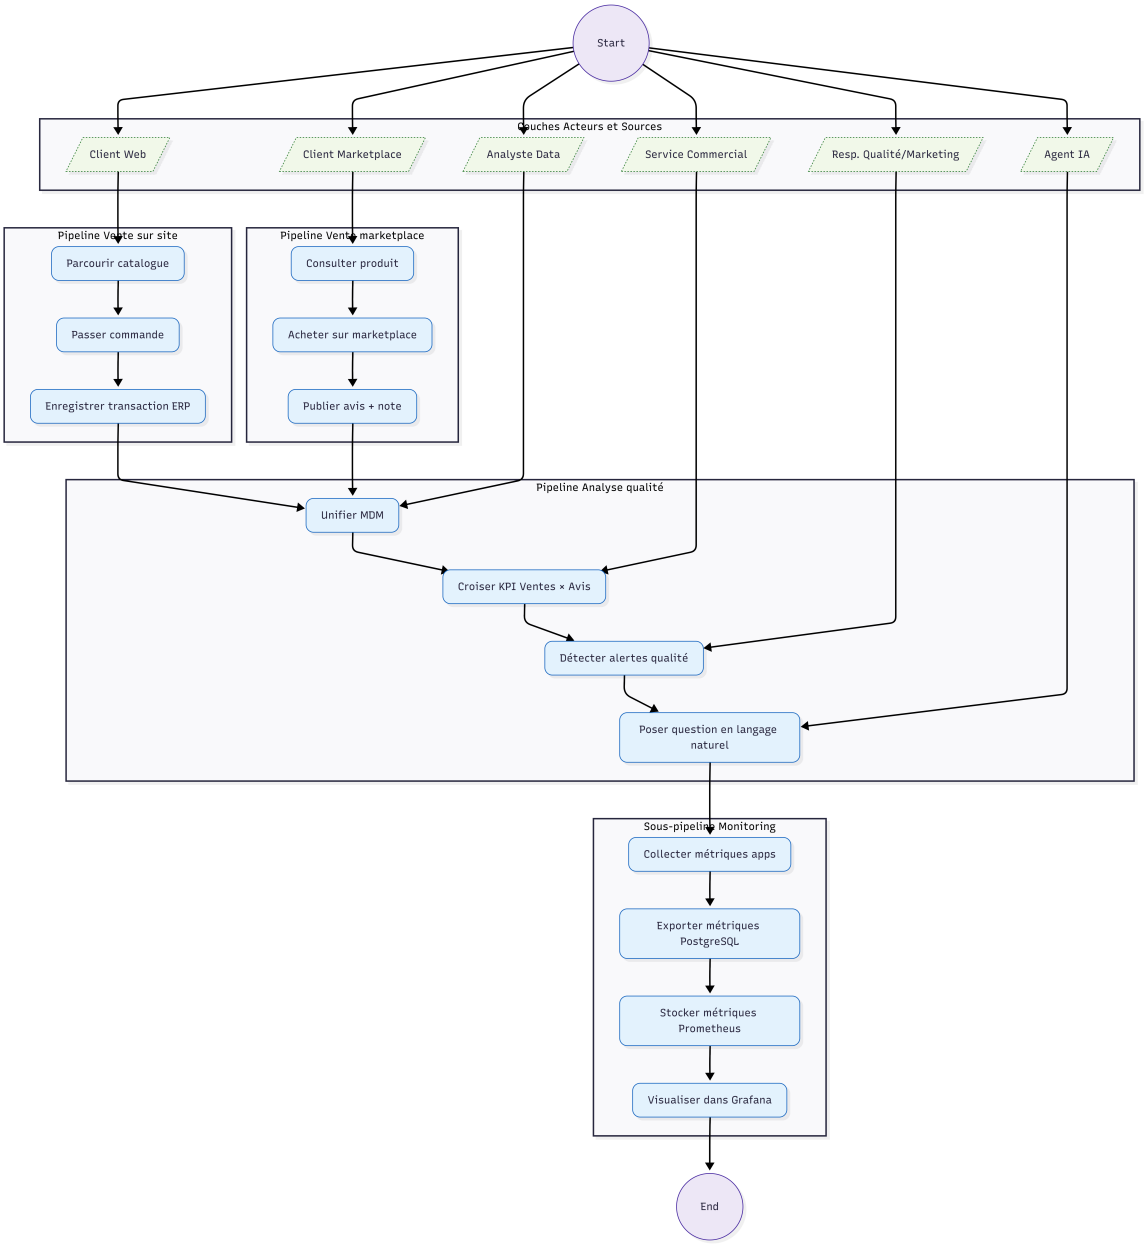

Références

2 Vue Transformation

Livrable Urbaniste – Vue Transformation

SmartShop 360

23 février 2026

Objectif

Distinguer clairement :
— **SI Opérationnel** (sources de données externes)
— **SI Décisionnel** (entrepôt PostgreSQL + vues analytiques)
Mettre en évidence le **Référentiel Produit (MDM)** comme pivot entre les silos.

Description de la transformation

1. Les sources `online_retail_II.csv` (ERP) et `labeledReview.datasetFix.json` (avis) arrivent dans l'ETL.
2. `incremental.py` compare les hashes SHA-256 et évite les rechargements inutiles.
3. `cleaning.py` et `data_quality.py` nettoient/valident les données.
4. `mdm_mapping.py` produit le pivot `product_mapping` (TF-IDF + fallback rank).
5. `run_etl.py` charge les tables et publie les vues `v_product_kpi`, `v_customer_kpi`, `v_alerts`, `v_data_quality`.
6. Les couches UI, Agent IA, Analytics/ML et monitoring consomment le SI décisionnel.

Séparation SI Opérationnel / SI Décisionnel

— **Opérationnel** : fichiers sources (CSV/JSON), données hétérogènes non jointes.
— **Pivot MDM** : `product_mapping` relie les identifiants ERP et Avis.
— **Décisionnel** : PostgreSQL 16 (tables `products`, `customers`, `sales_facts`, `review_facts`) + vues KPI.

Diagramme

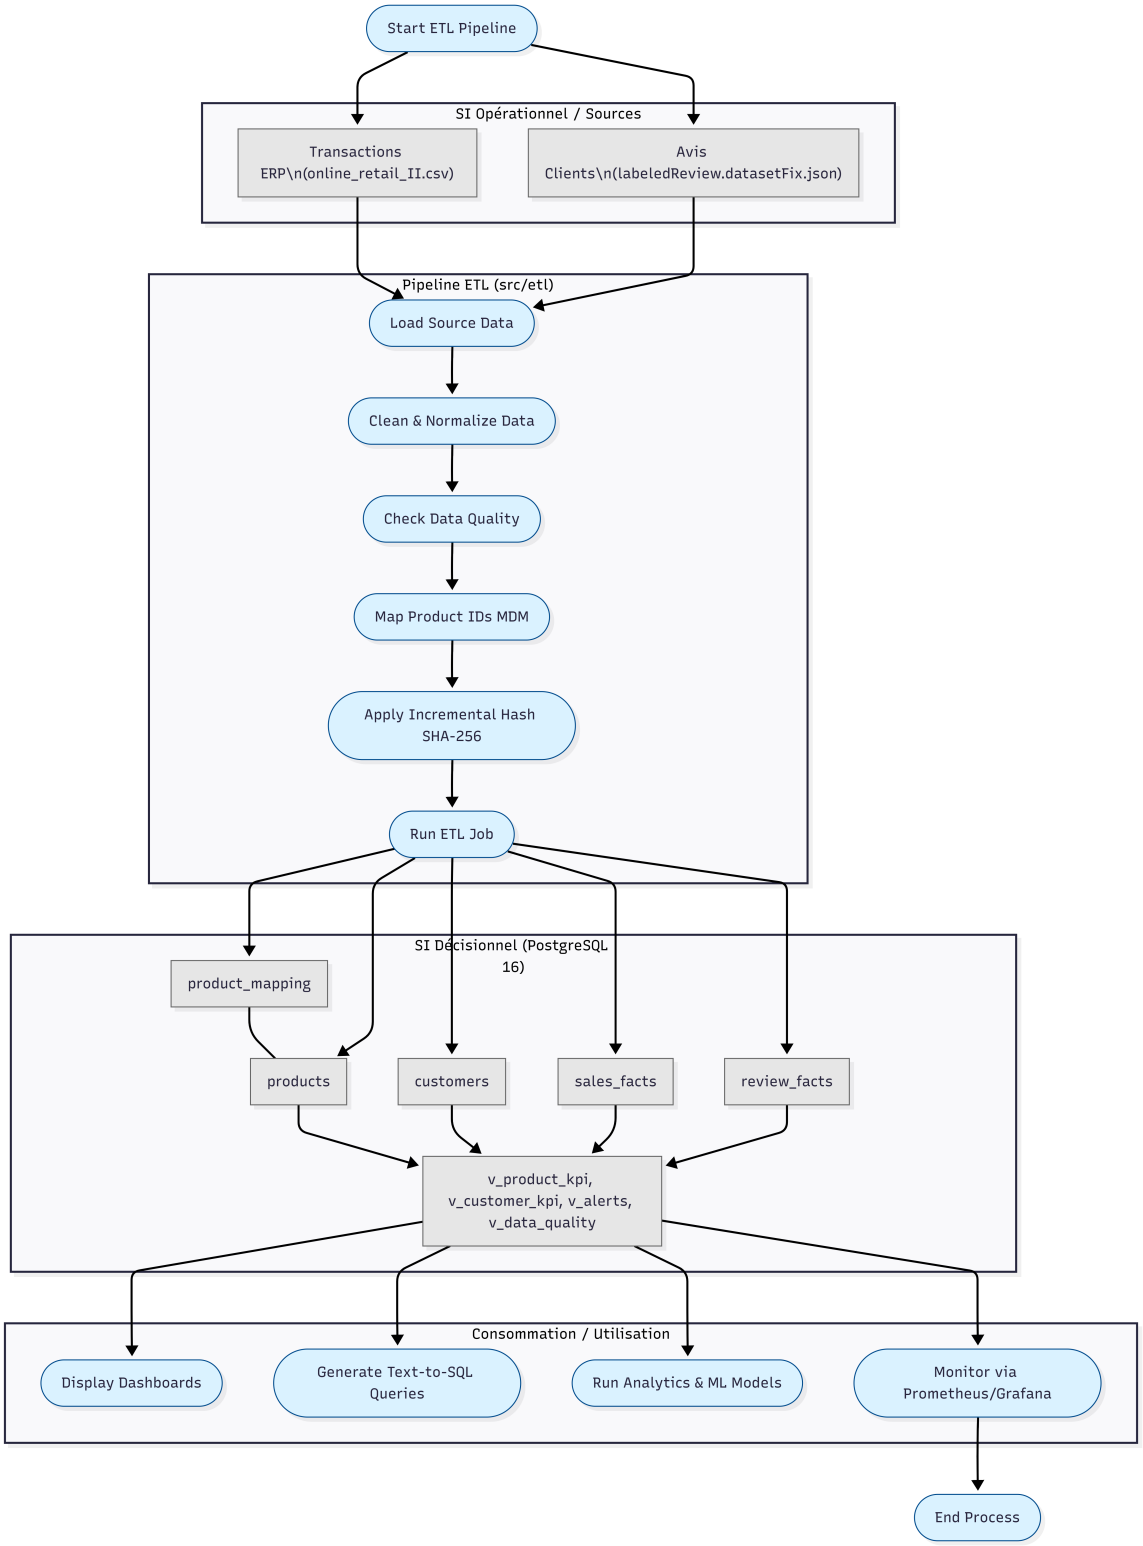
Start ETL Pipeline
SI Opérationnel / Sources
Transactions ERP\n(online_retail_II.csv)
Avis Clients\n(labeledReview.datasetFix.json)
Pipeline ETL (src/etl)
Load Source Data
Clean & Normalize Data
Check Data Quality
Map Product IDs MDM
Apply Incremental Hash SHA-256
Run ETL Job
SI Décisionnel (PostgreSQL 16)
product_mapping
products
customers
sales_facts
review_facts
v_product_kpi, v_customer_kpi, v_alerts, v_data_quality
Consommation / Utilisation
Display Dashboards
Generate Text-to-SQL Queries
Run Analytics & ML Models
Monitor via Prometheus/Grafana
End Process

3 DFD Pipeline ETL

Diagramme Technique – DFD Pipeline ETL

SmartShop 360

23 février 2026

Objectif

Détailler le flux de données de bout en bout :

Source → Nettoyage → Mapping/Unification → Base finale

Étapes du pipeline

1. Détection incrémentale : `should_run_etl()` compare les hashes des sources.
2. Ingestion/Nettoyage transactions : suppression annulations, quantités/prix invalides, calcul `Revenue` et `Margin`.
3. Ingestion avis : normalisation du sentiment et génération des notes.
4. Qualité : exécution des règles `run_all_validations()` sur transactions, avis et produits.
5. Mapping/Unification MDM : `build_product_mapping()` avec TF-IDF (seuil 0.35) et fallback rank.
6. Enrichissement avis : `attach_product_to_reviews()` + `ReviewDate`.
7. Chargement PostgreSQL : `products`, `customers`, `product_mapping`, `sales_facts`, `review_facts`.
8. Publication des vues analytiques : `v_product_kpi`, `v_customer_kpi`, `v_alerts`, `v_data_quality`.

Sorties principales

— Base finale relationnelle : PostgreSQL 16
— Vues KPI prêtes pour UI et Agent IA
— Historique incrémental des sources : `.etl_hashes.json`

Diagramme

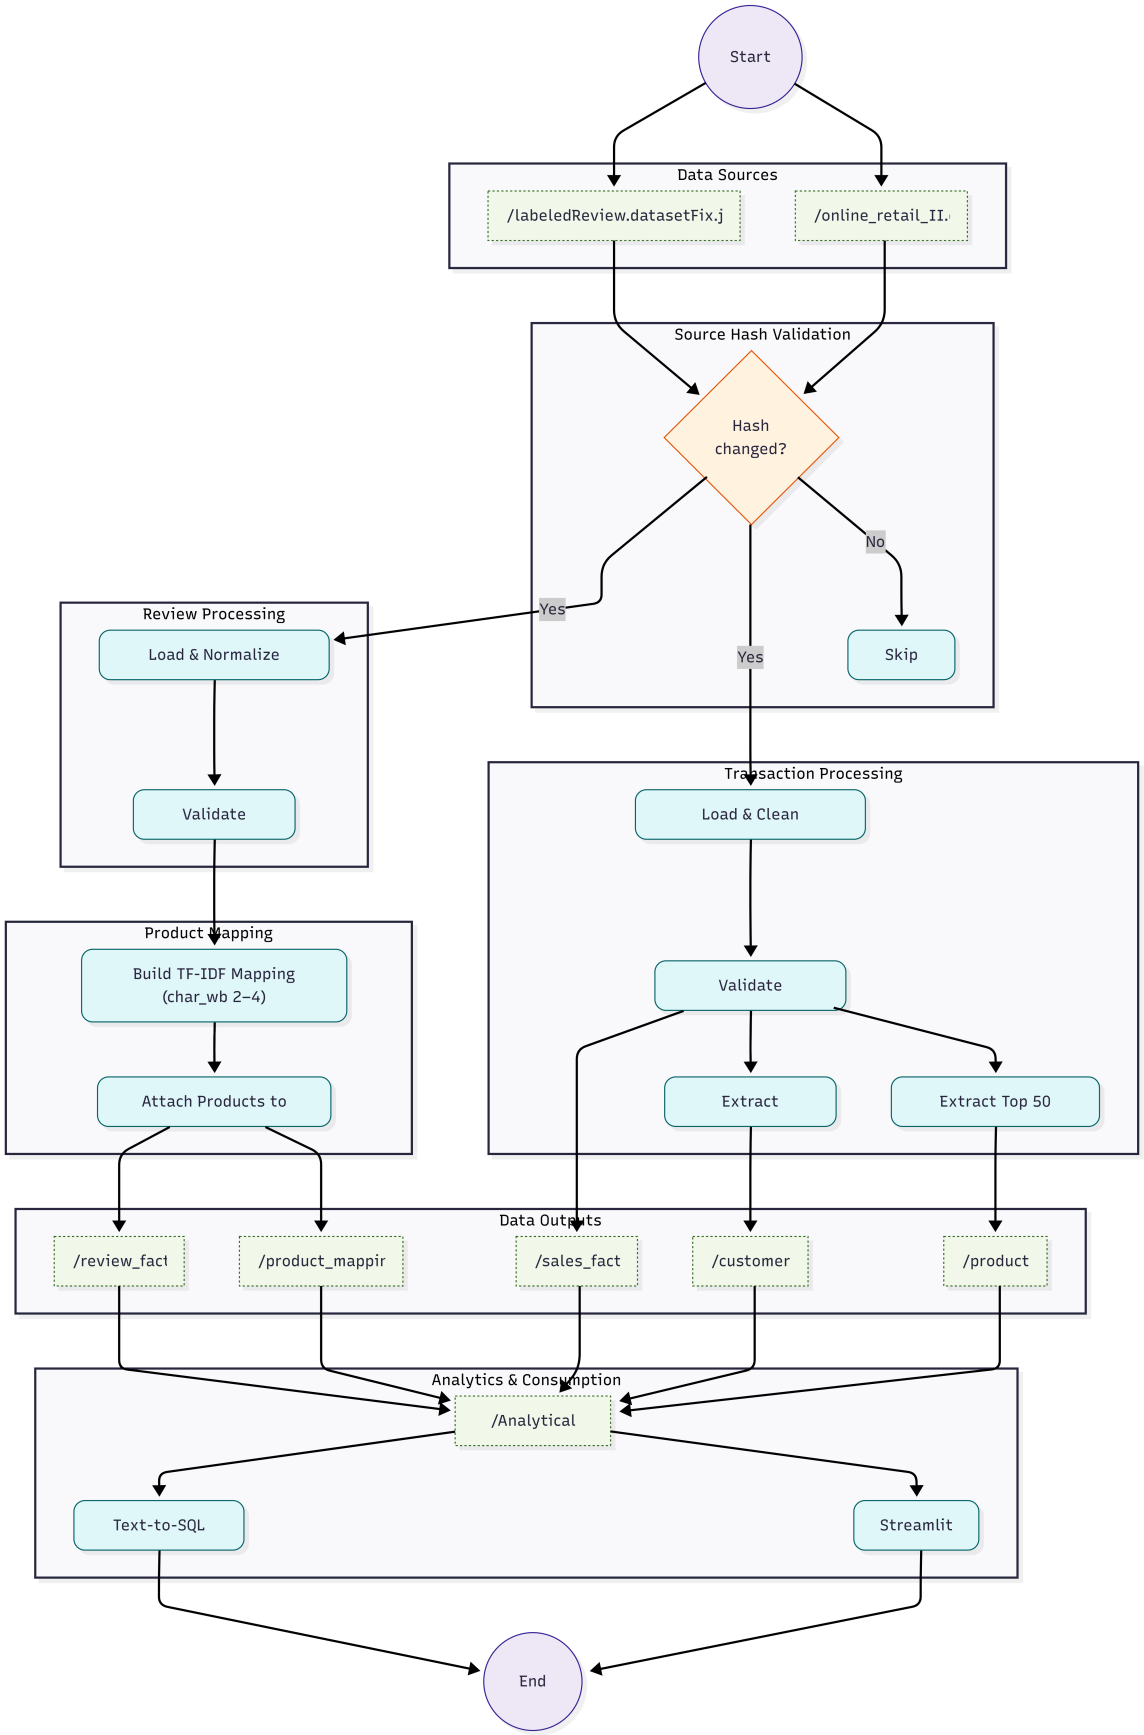
Start
Data Sources
/labeledReview.datasetFix.j
/online_retail_II.
Source Hash Validation
Hash changed?
No
Yes
Yes
Skip
Review Processing
Load & Normalize
Validate
Transaction Processing
Load & Clean
Product Mapping
Build TF-IDF Mapping (char_wb 2–4)
Attach Products to
Validate
Extract
Extract Top 50
Data Outputs
/review_fact
/product_mappir
/sales_fact
/customer
/product
Analytics & Consumption
/Analytical
Text-to-SQL
Streamlit
End

4 Architecture Physique

Diagramme Technique – Architecture Physique

SmartShop 360

23 février 2026

Objectif

Représenter les conteneurs applicatifs et les flux réseau :
— Conteneur PostgreSQL (`smartshop360_db`, port 5432)
— Conteneur App Python/Streamlit (`smartshop360_app`, port 8501)
— Endpoint métriques Prometheus (port 8000 côté app)
— Stack monitoring optionnelle (Prometheus/Grafana/Postgres Exporter)
— Flux vers API LLM externes (Groq, Mistral, OpenAI, Anthropic)

Description

L'application Streamlit/Python interagit avec PostgreSQL pour l'ETL, le MDM, les vues analytiques et le chat Text-to-SQL.

Le service `app` du `docker-compose.yml` exécute `python -m src.etl.run_etl` puis `streamlit run app.py`.

Le monitoring se déploie séparément via `monitoring/docker-compose.monitoring.yml` : Prometheus (9090), Grafana (3000), postgres_exporter (9187).

Flux techniques essentiels

1. Utilisateur → Streamlit (HTTP 8501)
2. Streamlit ↔ PostgreSQL (SQLAlchemy + pool)
3. Streamlit → API LLM externe (si clé disponible)
4. Prometheus ← endpoint `/metrics` de l'app (8000)
5. Grafana ← Prometheus (requêtes dashboards)

Diagramme

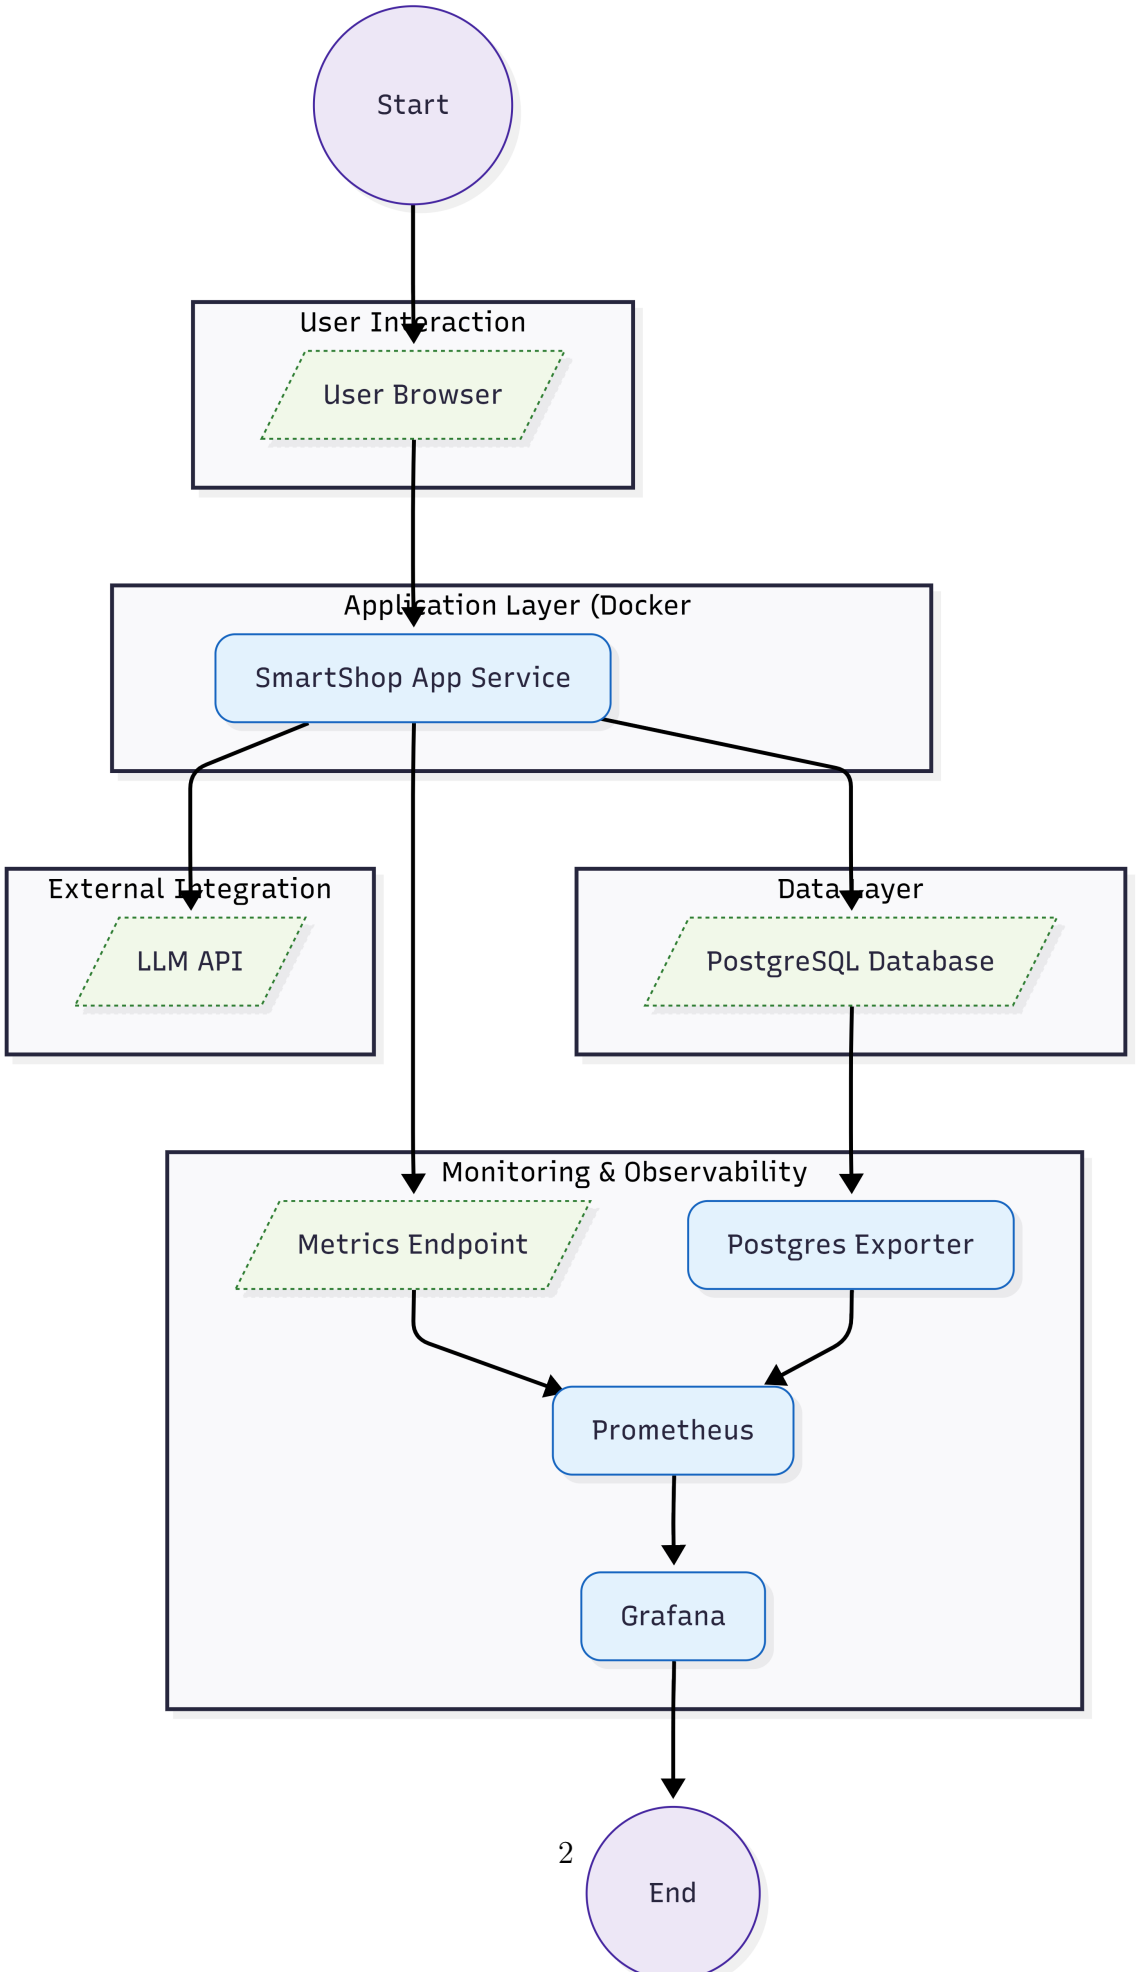
Start
User Interaction
User Browser
Application Layer (Docker
SmartShop App Service
External Integration
LLM API
Data Layer
PostgreSQL Database
Monitoring & Observability
Metrics Endpoint
Postgres Exporter
Prometheus
Grafana
End

5 Documentation Urbanistique & Métier

Documentation Urbanistique & Métier

SmartShop 360

23 février 2026

Table des matières

1 Stratégie MDM (Master Data Management)

1.1 Approche implémentée dans le projet

Le projet met en place une table pivot `product_mapping` qui joue le rôle de *golden record* produit entre la source ERP et la source avis. Le mapping repose sur :

— normalisation des libellés dans le pipeline ETL,

— rapprochement fuzzy TF-IDF (`char_wb`, n-grammes 2 à 4),

— seuil de similarité cosinus (0.35),

— fallback `rank` quand aucun match n'atteint le seuil,

— conservation du `MatchScore` et de `MatchStrategy` (traçabilité).

1.2 Approche recommandée en contexte réel

En production, la stratégie cible est hiérarchisée :

1. **EAN/GTIN** comme clé de référence quand disponible (matching déterministe),
2. **fuzzy matching** (Levenshtein + TF-IDF) quand le code universel est absent,
3. **matching sémantique** par embeddings pour cas difficiles,
4. revue humaine des cas ambigus,
5. traçabilité systématique (règle, score, date, validateur) et boucle d'amélioration.

2 Dictionnaire de données (tables clés)

2.1 Product_Mapping (pivot MDM)

Table de référence de rapprochement :

— `ERP_StockCode` et `Review_ProductCode`,

— nom unifié produit,

— catégorie,

— score et stratégie de matching.

2.2 Products

Table de référence produits ERP (Top 50 dans le POC) :

— `ProductID`, `ProductName`, `Category`

2.3 Customers

Table clients ERP :

— `ClientID`, `Nom`, `Pays`

2.4 Sales_Facts

Table de faits des ventes :

— granularité transactionnelle (facture/ligne),

— quantités, chiffre d'affaires, marge,

— clés vers produits et clients.

2.5 Review_Facts

Table de faits des avis :

— identifiant produit côté avis,

— note, sentiment, texte d'avis,

— date d'avis.

2.6 Vues analytiques

— `v_product_kpi` (CA, note, avis, quantités)

— `v_customer_kpi` (CA client, panier moyen, commandes)

— `v_alerts` (statuts `CRITIQUE`/`A_SURVEILLER`/`OK`)

— `v_data_quality` (couverture et volumétrie)

3 Scénario de démonstration (vidéo 5 à 10 min)

3.1 Script recommandé

1. **Contexte (30s)** : présenter les deux silos et l'absence d'identifiant commun.
2. **Ingestion ETL (2-3 min)** : lancer `streamlit run app.py` (ETL auto si base vide).
3. **Validation (1 min)** : montrer `product_mapping` + `v_product_kpi`.
4. **Question complexe à l'agent (2-3 min)** :
   "Quels produits vendus à plus de 50 exemplaires ont une note inférieure à 3 ?"
5. **Analyse de réponse (1-2 min)** : montrer le SQL généré, le résultat, et la décision métier.
6. **Robustesse (30s)** : démontrer le fallback hors-ligne (sans clé API) si nécessaire.

3.2 Critères de réussite

— cohérence entre les sources et les résultats,

— explicabilité des règles MDM,

— capacité de l'agent à répondre avec des données vérifiables,

— traçabilité : SQL généré + vues/colonnes utilisées.