SmartShop 360

Plateforme Data & Agent IA E-commerce

Rapport Technique

Stratégie MDM & Dictionnaire de Données

Projet	SmartShop 360
Domaine	E-commerce B2C (Décoration & Cadeaux)
Stack	PostgreSQL 16, Python 3.11, SQLAlchemy, scikit-learn
Date	Février 2026

Document généré à partir du code source du projet.

Table des matières

Contexte et problématique

SmartShop 360 agrège deux sources de données hétérogènes :

— **Source ERP** – fichier `online_retail_II.csv` (transactions de vente : `Invoice`, `StockCode`, `Description`, `Quantity`, `UnitPrice`, `CustomerID`, `Country`).
— **Source Avis** – fichier JSON `labeledReview.datasetFix.json` (avis clients crawlés sur une marketplace : `ProductName`, `ReviewText`, `Sentiment`, `Note`).

Problème central

Les deux sources décrivent les mêmes produits physiques, mais sans clé commune : l'ERP identifie un produit par son `StockCode` (ex. `85123A`), tandis que la source avis utilise un nom textuel libre (ex. *"White Hanging Heart Tlight Holder"*).

L'enjeu du **Master Data Management (MDM)** est de créer une table de correspondance (*Golden Record*) reliant chaque article ERP à ses avis clients, afin de calculer des KPI croisés (CA × Note × Réputation).

Stratégie MDM – Choix et justifications

Architecture générale du pipeline MDM

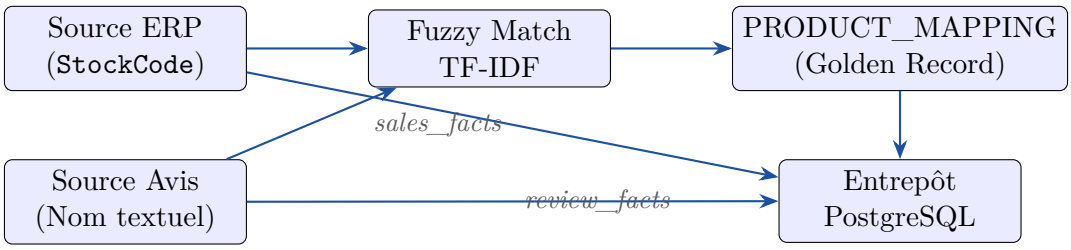

Niveaux de matching – hiérarchie de priorité

#	Stratégie	Description	Fiabilité	Contexte
1	Hard Match (EAN/GTIN)	Code-barres universel commun aux deux sources	100 %	Production
2	Fuzzy Match (TF-IDF + cosinus)	Vectorisation par n-grammes de caractères ; seuil cosinus $\geq 0{,}35$	70–90 %	Implémenté
3	Semantic Match (Sentence-BERT)	Embeddings 384 dimensions + `pgvector` ; robuste aux noms très différents	60–85 %	Implémenté (RAG)
4	Rank-based (POC)	Association rang par rang (Top-50 ERP ↔ Top-50 avis)	Artificielle	POC uniquement

Implémentation POC – Fuzzy Match TF-IDF

Algorithme

L'implémentation se trouve dans `src/etl/mdm_mapping.py`. Le vecteur TF-IDF est construit en mode **character n-grams** (`char_wb`, $n \in [2, 4]$) pour être robuste aux :

— fautes d'orthographe et abréviations (ex. *"Tlight"* vs *"T-Light"*) ;
— différences de casse et d'espacement ;
— noms partiels (*"Cupid Hearts Coat"* vs *"Cream Cupid Hearts Coat Hanger"*).

Extrait – `fuzzy_match_tfidf()` dans mdm_mapping.py

```
vectorizer = TfidfVectorizer(
    analyzer    = "char_wb",   # n-grammes de caracteres
    ngram_range = (2, 4),
    lowercase   = True,
)
tfidf_matrix = vectorizer.fit_transform(erp_names + review_names)

# Matrice de similarite cosinus (n_erp x n_review)
sim_matrix = cosine_similarity(erp_vec, rev_vec)

# Meilleur match si score >= seuil
for erp_idx in range(n_erp):
    best_rev_idx = np.argmax(sim_matrix[erp_idx])
    best_score   = sim_matrix[erp_idx, best_rev_idx]
    if best_score >= threshold:   # threshold = 0.35
        matches[erp_idx] = (best_rev_idx, best_score)
```

Paramètres retenus

Paramètre	Valeur	Justification
`analyzer`	`char_wb`	Robustesse aux fautes ; pas de dépendance lexicale
`ngram_range`	$(2, 4)$	Capte les di-, tri- et quad-grammes de caractères
`threshold`	0,35	Équilibre précision/rappel sur données UK retail
`SAMPLE_SIZE`	30 000	Représentatif ; limite le temps de vectorisation

Résultat – table `product_mapping`

La fonction `build_product_mapping()` produit un *Golden Record* par produit ERP, avec les colonnes suivantes :

Colonne	Type	Signification
`MappingID`	SERIAL	Clé surrogate auto-incrémentée
`ERP_StockCode`	VARCHAR	Code article source ERP
`ERP_ProductName`	VARCHAR	Libellé ERP brut
`Review_ProductCode`	VARCHAR	Code article côté avis (`REV_001...`)
`Review_ProductName`	VARCHAR	Libellé avis brut
`Category`	VARCHAR	Catégorie inférée (règles mots-clés)
`GoldenRecordName`	VARCHAR	Nom unifié retenu (Golden Record)
`MatchScore`	FLOAT	Score cosinus TF-IDF $\in [0, 1]$
`MatchStrategy`	VARCHAR	`tfidf` ou `rank`

Stratégie production – Comment nous aurions procédé en contexte réel

Dans un contexte réel, le pipeline MDM suivrait une cascade de quatre niveaux de confiance décroissante.

Niveau 1 – Hard Match par code EAN/GTIN (déterministe)

Principe

Chaque produit physique porte un code-barres EAN-13 ou GTIN-14 unique au monde. Si l'ERP et la plateforme d'avis exposent cette valeur, la réconciliation est déterministe et ne nécessite aucun algorithme.

Condition préalable : l'ERP doit stocker le GTIN dans une colonne dédiée, et le crawler d'avis doit extraire le GTIN depuis la fiche produit marketplace.

Implémentation :

```sql
-- Jointure deterministe sur GTIN
UPDATE product_mapping pm
SET    "Review_ProductCode" = r."ProductID",
       "MatchStrategy"      = 'ean_hard',
       "MatchScore"         = 1.0
FROM   review_source r
WHERE  pm."ERP_GTIN" = r."GTIN"
  AND  pm."MatchStrategy" IS NULL;
```

Fiabilité : 100 %. Aucun faux positif possible.

Niveau 2 – Fuzzy Match sur les noms (Levenshtein + TF-IDF)

Pour les produits sans GTIN commun, on applique deux algorithmes en parallèle et on combine leurs scores :

Algorithme	**Avantage**	**Limite**
Distance de Levenshtein (`thefuzz`)	Simple, intuitif, seuil ≥ 90 pour un lien automatique	Sensible aux transpositions (*"Red Bag"* vs *"Bag Red"*)
TF-IDF caractères + cosinus (`scikit-learn`)	Robuste aux fautes, ordres de mots	Requiert corpus suffisant ; seuil à calibrer

Règle de décision :

$$\text{score}_{final} = \alpha \cdot \text{Levenshtein} + (1-\alpha) \cdot \text{TF-IDF\_cosinus} \quad (\alpha = 0{,}5)$$

Si $\text{score}_{final} \geq 0{,}80$: lien automatique.
Si $0{,}50 \leq \text{score}_{final} < 0{,}80$: proposition à validation humaine.
Si $\text{score}_{final} < 0{,}50$: non apparié, envoyé en niveau 3.

Niveau 3 – Semantic Match par embeddings (Sentence-BERT + pgvector)

Pour les noms trop différents stylistiquement mais dénotant le même produit (ex. *"Coeur Blanc Lumineux Suspendu"* vs *"White Hanging Heart T-Light Holder"*), les embeddings sémantiques capturent le sens au-delà de la forme.

```
# Deja implemente dans src/agent/rag.py
from sentence_transformers import SentenceTransformer
model = SentenceTransformer("all-MiniLM-L6-v2")  # 384 dimensions

# Stockage dans PostgreSQL via pgvector
# CREATE EXTENSION IF NOT EXISTS vector;
# ALTER TABLE products ADD COLUMN embedding vector(384);
# CREATE INDEX ON products USING ivfflat (embedding vector_cosine_ops);
```

Niveau 4 – Validation humaine (stewardship)

Les cas ambigus ($0{,}50 \leq \text{score} < 0{,}80$) sont soumis à un *Data Steward* via une interface de revue (tableau Kanban ou micro-tâche). Le retour humain alimente un ensemble d'entraînement pour améliorer les seuils en continu (*active learning*).

Gouvernance MDM en production

Dimension	**Mesure**
Couverture	% produits ERP ayant au moins un avis lié
Précision	% liens validés comme corrects par audit
Fraîcheur	Délai max entre mise à jour ERP et re-match
Traçabilité	Colonne `MatchStrategy` + horodatage

Dictionnaire de données

L'entrepôt SmartShop 360 est hébergé dans PostgreSQL 16. Il suit un schéma en **étoile** : une table de faits de ventes, une table de faits d'avis, et trois dimensions (produit, client, mapping MDM).

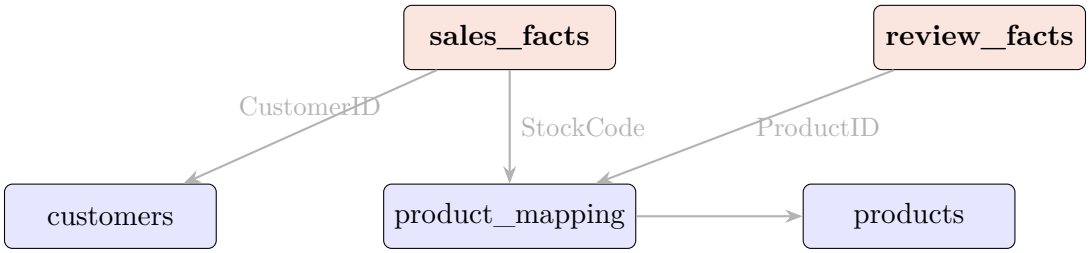

Table `product_mapping` (Unified Product / Golden Record)

Table pivot centrale du MDM. Chaque ligne est un *Golden Record* qui relie un article ERP à son équivalent dans la source avis.

Colonne	Type SQL	Nullable	Description
`MappingID`	SERIAL	NON	Clé primaire auto-incrémentée
`ERP_StockCode`	VARCHAR(50)	OUI	Code article dans l'ERP (ex. `85123A`)
`ERP_ProductName`	VARCHAR(256)	OUI	Libellé brut extrait du CSV ERP
`Review_ProductCode`	VARCHAR(50)	OUI	Code produit côté avis (ex. `REV_001`)
`Review_ProductName`	VARCHAR(256)	OUI	Libellé brut extrait du fichier JSON
`Category`	VARCHAR(100)	OUI	Catégorie consolidée (7 valeurs : Luminaires, Sacs & Accessoires, Art de la Table, Decoration Murale, Emballages & Cadeaux, Nature & Romantique, Divers)
`GoldenRecordName`	VARCHAR(256)	OUI	Nom unifié retenu pour l'affichage (Golden Record)
`MatchScore`	FLOAT	OUI	Score de similarité cosinus TF-IDF $\in [0, 1]$; 0.0 si fallback rang

Colonne	Type SQL	Nullable	Description
`MatchStrategy`	VARCHAR(20)	OUI	Stratégie utilisée : `tfidf` ou `rank`

Clés étrangères (cible production) :
- `ERP_StockCode` → `products.ProductID`
- `Review_ProductCode` → `review_facts.ProductID`

Table `sales_facts` (Faits de Ventes)

Granularité : **une ligne = une ligne de facture ERP** (article + quantité + date). Chargée depuis le CSV *Online Retail II* (échantillon de 30 000 lignes, graine 42).

Colonne	Type SQL	Nullable	Description
`FactID`	SERIAL	NON	Clé primaire surrogate
`InvoiceNo`	VARCHAR(20)	OUI	Numéro de facture (ex. `536365`) ; les codes commençant par `C` (annulations) sont exclus lors du nettoyage
`StockCode`	VARCHAR(50)	OUI	Code article ERP ; clé étrangère vers `product_mapping.ERP_StockCode`
`Quantity`	INTEGER	OUI	Quantité vendue (> 0 après nettoyage)
`Revenue`	NUMERIC(12,2)	OUI	Chiffre d'affaires = `Quantity` × `UnitPrice`
`Margin`	NUMERIC(12,2)	OUI	Marge simulée = `Revenue` × 0,35 (taux fixe POC)
`InvoiceDate`	TIMESTAMP	OUI	Date et heure de la facture
`CustomerID`	VARCHAR(50)	OUI	Identifiant client ; clé étrangère vers `customers.ClientID`

Règles de nettoyage appliquées :
- Suppression des factures annulées (`InvoiceNo` commence par `'C'`).

— Suppression des lignes avec `Quantity` ≤ 0 ou `UnitPrice` ≤ 0.
— Suppression des lignes avec `CustomerID` manquant.
— Calcul de `Revenue` et `Margin` post-nettoyage.

Vues dérivées :
— `v_product_kpi` – CA, marge, quantité vendue agrégés par produit.
— `v_customer_kpi` – CA total, panier moyen, nb commandes par client.
— `v_alerts` – statut CRITIQUE / A_SURVEILLER / OK par produit (seuils : Note $< 3{,}0$ ET Qté > 50 = CRITIQUE ; Note $< 3{,}5$ = A_SURVEILLER).

Table `review_facts` (Faits d'Avis Clients)

Granularité : **une ligne = un avis client**. Chargée depuis le JSON `labeledReview.datasetFix.json` (données réelles crawlées).

Colonne	Type SQL	Nullable	Description
`ReviewID`	SERIAL	NON	Clé primaire surrogate auto-incrémentée
`ProductID`	VARCHAR(50)	OUI	Code produit côté avis (`REV_001...`) ; clé étrangère vers `product_mapping.Review_ProductCode`
`Rating`	NUMERIC(3,1)	OUI	Note attribuée par le client $\in [1{,}0; 5{,}0]$; simulée depuis le champ `Note` du JSON (distribution normale)
`ReviewText`	TEXT	OUI	Texte intégral de l'avis client (utilisé pour les embeddings RAG)
`Sentiment`	VARCHAR(20)	OUI	Sentiment binaire : `positive` (champ `sentimen` = 1) ou `negative` (champ `sentimen` = 0) ; pas de neutre dans ce jeu de données
`ReviewDate`	TIMESTAMP	OUI	Date de l'avis ; simulée sur 18 mois (2024-01-01 à 2025-06-30) avec graine 42

Table dérivée – `review_embeddings` (hors DDL principal) :

Colonne	Type SQL	Description
`id`	SERIAL	Clé primaire
`review_id`	INTEGER	Référence vers `review_facts.ReviewID`
`embedding`	vector(384)	Vecteur d'embedding Sentence-BERT (`all-MiniLM-L6-v2`)

Indexé avec `ivfflat` (extension `pgvector`) pour la recherche ANN (*Approximate Nearest Neighbour*) dans le module RAG.

Synthèse des choix techniques

Besoin	Choix retenu	Justification
Matching flou de noms	TF-IDF char n-grams + cosinus	Robustesse aux fautes, pas de dépendance externe
Matching sémantique	Sentence-BERT + pgvector	Capte la sémantique au-delà de la forme lexicale
Catégorisation produit	Règles mots-clés (7 catégories)	Reproductible, explicable, sans ML
Seuil de matching	0,35 (TF-IDF cosinus)	Calibré expérimentalement sur données UK retail
Stockage	PostgreSQL 16 + pgvector	SQL standard + indexation vectorielle native
Reproductibilité ETL	SHA-256 + `.etl_hashes.json`	Détection incrémentale des changements de source